

Sistema preditivo de scouting esportivo: avaliação de aptidão divisional de jogadores de futebol no Campeonato Brasileiro usando aprendizado de máquina

Felipe Santos de Jesus^{1*}; Profa. Flávia Priscila Dantas²

¹ Escola Politécnica da Universidade de São Paulo (POLI-USP). Aluno do Programa de MBA em Data Science & Analytics para Operações.

² Escola Politécnica da Universidade de São Paulo (POLI-USP). Professora do Programa de MBA em Data Science & Analytics para Operações.

Resumo

O processo de recrutamento no futebol profissional contemporâneo envolve riscos financeiros elevados e tradicionalmente baseou-se em análises subjetivas de olheiros. Este trabalho desenvolveu um sistema preditivo fundamentado em Aprendizado de Máquina para avaliar a aptidão divisional de jogadores para as Séries A e B do Campeonato Brasileiro, atuando como ferramenta de mitigação de risco financeiro. Consolidou-se um banco de dados com 13.663 registros históricos de atletas (temporadas de 2010 a 2024), extraídos do portal FBref. Após a aplicação de filtro de minutagem mínima (≥ 300 minutos, restando 8.752 registros qualificados), engenharia de atributos para a normalização de métricas por 90 minutos (/90) e padronização Z-Score via StandardScaler, estruturou-se a validação dos modelos sob o paradigma temporal Out-of-Time (treinamento com dados de 2010-2020 e teste com dados de 2021-2024). Avaliaram-se os algoritmos de Regressão Logística, Random Forest e Gradient Boosting posicional. O modelo Gradient Boosting Posicional alcançou F1-Score de 0,8600 para Atacantes de Área (Acurácia 85,90%) e 0,8350 para Goleiros (Acurácia 83,80%, ROC-AUC 0,9130). Demonstrou-se empiricamente que a ausência de normalização provoca o colapso catastrófico de gradiente na Regressão Logística (0,00% de Precisão e Recall). Justificou-se o escopo tático pelas limitações de variáveis macro para Defensores e Meias. Validou-se qualitativamente a utilidade da solução por estudos de caso longitudinais de oito atletas e pela implantação em um Web-App interativo em Streamlit.

Palavras-chave: Inteligência Artificial; Mineração de Dados; Validação Temporal; Estatísticas Esportivas; Scouting de Futebol

Abstract

The player recruitment process in contemporary professional football involves high financial risks and has traditionally relied on subjective scout evaluations. This work developed a machine learning-based predictive system to assess player divisional suitability for Series A and B of the Brazilian National Championship as a tool for financial risk mitigation. A database of 13,663 historical player-season records (2010-2024 seasons) was compiled from the FBref portal. Following play-time filtering (≥ 300 minutes, retaining 8,752 qualified records), feature engineering per 90 minutes (/90), and Z-Score standardization via StandardScaler, model validation was structured under an Out-of-Time temporal framework (training on 2010-2020 and testing on 2021-2024). Logistic Regression, Random Forest, and Position-Specialized Gradient Boosting algorithms were evaluated. The Positional Gradient Boosting model achieved a weighted F1-Score of 0.8600 for Forwards (85.90% Accuracy) and 0.8350 for Goalkeepers (83.80% Accuracy, ROC-AUC 0.9130). It was empirically proven that unscaled Logistic Regression suffers catastrophic gradient collapse (0.00% Precision and Recall). The tactical scope was justified due to macro-feature limitations for Defenders and Midfielders. The practical utility of the solution was qualitatively verified through longitudinal career case studies of eight players and deployed via an interactive Streamlit web application.

Keywords: Artificial Intelligence; Data Mining; Temporal Validation; Sports Statistics; Football Scouting.

Introdução

O mercado internacional do futebol movimenta anualmente dezenas de bilhões de dólares em transações de direitos federativos, salários e direitos comerciais de transmissão de mídia. No cenário brasileiro contemporâneo, a promulgação da Lei n 14.193/2021 viabilizou a constituição da Sociedade Anônima do Futebol (SAF), provocando uma transição sem precedentes nos clubes nacionais. Sob essa nova perspectiva corporativa, a governança financeira, a eficiência na alocação de recursos e o retorno sobre o investimento (ROI) tornaram-se métricas de sobrevivência institucional.

Diante dessas condições de risco, a Ciência de Dados aplicada ao scouting esportivo atua como uma ferramenta analítica de mitigação de risco corporativo de extrema relevância (SAYAN; HANÇER, 2022). Este trabalho adota a validação temporal Out-of-Time (Treino 2010-2020, Teste cego 2021-2024), justifica a escolha de modelos tabulares interpretáveis (GRINSZTAJN et al., 2022) e delimita o escopo às Séries A e B (2010-2024). O objetivo geral consiste em desenvolver, avaliar e implantar um sistema preditivo para estimar a aptidão divisional de jogadores de futebol, servindo de suporte

quantitativo ao recrutamento profissional.

Material e Métodos ou Método

A pesquisa classifica-se como Aplicada, Quantitativa, Exploratorio-Descritiva, Documental e de Implementacao de Algoritmo. A base consolidada (13.663 registros) passou por filtro de corte minimo de 300 minutos (retendo 8.752 registros) e padronizacao Z-Score via StandardScaler. Para garantir rigor estatistico contra vazamento de dados (data leakage), a validacao foi conduzida estritamente no paradigma temporal Out-of-Time (Treino 2010-2020, Teste cego 2021-2024).

1. Buscador Preditivo SAD e Taxonomia Tripartida:

O modelo Gradient Boosting Posicional estima a probabilidade P(Serie A) de cada atleta. A classificacao final adota taxonomia tripartida: (a) Titular de Elite (Serie A) para $P \geq 75\%$; (b) Reserva Qualificado (Serie A) para $50\% \leq P < 75\%$; e (c) Inapto (Nem Titular nem Reserva de Serie A) para $P < 50\%$.

2. Simulador Tecnico ('What-If') e Formula de Similaridade (Scouting Match):

Para identificar atletas reais com estatisticas semelhantes ao perfil simulado nos sliders, o sistema calcula a Distancia Euclidiana Normalizada Ponderada (Dj):

$$D_j = \frac{\sum (w_i * |X_{i,atleta} - X_{i,simulado}|)}{\sigma_i}$$

Os pesos das variaveis (wi) refletem a prioridade tatica posicional:

- Atacantes / Meio-Campistas: $w_{gols} = 3,0$ (produtividade), $w_{ast} = 1,5$ (criacao), $w_{starts} = 1,0$ (titularidade), $w_{min} = 1,0$ (volume), $w_{idade} = 0,5$.
- Goleiros: $w_{gols_sofridos} = 3,0$ (solidez defensiva), $w_{starts} = 1,0$, $w_{min} = 1,0$, $w_{idade} = 0,5$.
- Defensores: $w_{cartoes_amarelos} = 2,0$ (disciplina/risco), $w_{gols_sofridos} = 2,0$, $w_{starts} = 1,0$, $w_{min} = 1,0$, $w_{idade} = 0,5$.

A similaridade percentual e obtida por: $Similaridade\ (\%) = \max(50\%, 100\% - D_j * 15\%)$.

Etapas de Processamento	Descrição Operacional	Volume (N)	Percentual (%)
Registros Originais Brutos	Atletas-Temporada consolidados (2010-2024)	13.663	100,0%
Filtro de Descarte (Min < 300)	Registros de amostragem insignificante	4.911	35,9% (Removidos)
Base Final Qualificada	Base tratada com significância estatística	8.752	64,1% (Retidos)
Treinamento Out-of-Time	Dados históricos (2010 a 2020)	4.849	35,5% do total
Teste Independente Cego	Dados futuros Out-of-Time (2021 a 2024)	3.903	28,6% do total

Resultados e Discussão

A Tabela 4 resume o desempenho comparativo dos modelos no conjunto de teste cego Out-of-Time (2021-2024):

Modelo / Posição	Pipeline	Acurácia	Precisão	Recall	F1-Weighted / AUC
LogReg (Sem Scaler - Genérico)	Dados Brutos	50,65%	0,00%	0,00%	0,3406 / N/A
LogReg (Sem Scaler - Goleiro)	Dados Brutos	81,90%	0,00%	0,00%	0,7376 / N/A
LogReg (Sem Scaler - Atacante)	Dados Brutos	78,19%	56,00%	20,59%	0,7408 / N/A
Genérico (Com Scaler)	LogReg + StandardScaler	53,34%	53,50%	41,69%	0,5271 / 0.5355
Genérico (Com Scaler)	RandForest + StandardScaler	74,80%	72,10%	71,50%	0,7480 / 0.8120
SAD Atacante (GradBoost)	GradBoost + StandardScaler	85,90%	81,20%	78,40%	0,8600 / 0.8710
SAD Goleiro (GradBoost)	GradBoost + StandardScaler	83,80%	79,50%	74,10%	0,8350 / 0.9130

Conclusão ou Considerações Finais

O sistema preditivo desenvolvido cumpriu os objetivos propostos ao mapear a aptidão divisional para as Séries A e B do futebol brasileiro, entregando os resultados em um Web-App interativo em Streamlit (app/app.py). A normalização via StandardScaler é requisito indispensável para evitar o colapso de gradiente. O filtro de 300 minutos eliminou o ruído de pequenas amostras e a especialização posicional elevou o F1-Score para 0,8600 em Atacantes e 0,8350 em Goleiros.

Referências

- CARLING, C. et al. The Role of Motion Analysis in Elite Soccer. Sports Medicine, v. 38, n. 10, p. 839-862, 2008.
- GRINSZTAJN, L. et al. Why Do Tree-Based Models Still Outperform Deep Learning on Typical Tabular Data? NeurIPS 35, 2022.
- HUGHES, M.; FRANKS, I. M. Essentials of Performance Analysis in Sport. 3. ed. London: Routledge, 2019.
- MEMMERT, D.; RAABE, D. Data Analytics in Football: Positional Data Collection, Modelling and Analysis. London: Routledge, 2018.
- SAYAN, V. H.; HANÇER, E. A Survey on Football Player Performance Estimation Using Machine Learning. MAKU Techno-Science, 2022.
- TANG, Q. et al. The Role of Machine Learning in Talent Identification for Team Sports. JSSM, v. 25, p. 58-83, 2026.
- VILELA, T. et al. Towards a Pervasive Intelligent System on Football Scouting. Springer, AISC, v. 747, p. 341-351, 2018.

Apêndice(s) e Anexo(s)

Apêndice A. Repositório de Código-Fonte e Execução da Aplicação

Código-fonte público disponível no GitHub: <https://github.com/felipesjh/analise-aptidao-futebol-tcc.git>

Anexo A. Relatórios e Certificados do Turnitin (Espaço Reservado)

(Espaço reservado para inserção da folha de aprovação do Turnitin e índice de similaridade gerado pela Secretaria Acadêmica da Poli/USP).