



Data Analysis & Data Visualization

Eduardo Tiecher

Um modelo de passo a passo para projetos de DS



Cross Industry Standard Process for Data Mining

<https://recipp.ipp.pt/bitstream/10400.22/136/3/KDD-CRISP-SEMMA.pdf>

<https://www.kde.cs.uni-kassel.de/wp-content/uploads/lehre/ws2012-13/kdd/files/CRISPWP-0800.pdf>

Data Analysis

Análise e Tratamento de Dados

- Características do(s) dataset(s)
 - Variáveis independentes, dimensões, tipos, unidade de análise, natureza dos dados
 - Qualidade dos dados, distribuição, relações
- Tratamentos
 - Separação treino, teste e validação
 - Valores faltantes, valores extremos, duplicidade, padronização e limpeza
 - Tratamento de tipos (categóricas nominais/ordinais ou quantitativas)
 - Normalização, balanceamento, dimensionalidade, amostragem
 - Transformação de dados
- Dados não estruturados (texto, áudio, imagem, vídeo)

Data Visualization

Visualização de dados

- Elementos da comunicação
 - Cores, formas, distribuição, símbolos, textos, evolução
- Abordagem
 - Clareza, foco, ordem, hierarquia, síntese
- Viés
- Visualização de dados no processo analítico e no processo gerencial
- Ferramentas e funcionalidades
 - Complexidade/simplicidade, disponibilidade, interatividade, custo (direto e indireto)

Linhas de pesquisa

Análise de dados

- Impacto das técnicas na performance dos modelos
- Revisão das técnicas, benefícios e malefícios, adequação estatística, recomendações de aplicações

Visualização de dados

- Modelos de referência para aplicações específicas (ex.: georreferenciamento real-time para problemas de otimização de rotas)
- Adaptação de processos de negócio para orientação a dados