



Implementação de um Pipeline de Dados

Fernando Nakamuta


Implementação de um Pipeline de Dados

Importância de linha de pesquisa

- Qualquer projeto que use os dados de forma automática irá depender de um pipeline de dados. Isso garantirá com que novos dados sejam coletados, processados e analisados recorrentemente;
- O profissional que sabe construir pipelines de dados saudáveis e escaláveis em um contexto promissor tem a capacidade de alterar a realidade de uma empresa e até mesmo criar novos negócios;
- Se dados são o novo petróleo, estamos falando aqui do processo de extração e disponibilização do petróleo para ser refinado no futuro.

Implementação de um Pipeline de Dados

Importância de linha de pesquisa



Implementação de um Pipeline de Dados

Exemplos de trabalhos aplicados

- Extração e análise de dados de APIs públicas (ex: twitter, weather, gmaps);
- Construção de dashboards através de dados coletados por web scraping;
- Coleta e armazenamento de dados coletados por dispositivo de IOT (ex: raspberry PI) em tempo real;
- Estruturação das previsões de um modelo de machine learning;
- Proposta de arquitetura de um pipeline de dados incluindo um modelo de machine learning end-to-end;

Implementação de um Pipeline de Dados

Método de trabalho


- Utilização dos serviços em nuvem de algum provedor de Cloud (AWS, Azure, Google Cloud, etc);
- Aplicação do conhecimento acadêmico em dados reais;
- Desenvolvimento de código fonte (qualquer linguagem) ou ferramenta para realizar o ETL;
- Código mantido e versionado como projeto público no github;
- Visualização dos resultados em dashboards.

Implementação de um Pipeline de Dados


Formas de apresentação de resultados



Dashboard
Público



Aplicação de modelo de
machine learning



Pipeline
de dados

Mostrar processo,
ferramentas e banco
de dados

Implementação de um Pipeline de Dados

Referencias bibliográficas

- Kimball, R., & Ross, M. (2013). ***The Data Warehouse Toolkit: The Definitive Guide to Dimensional Modeling***. 3rd ed. John Wiley & Sons. Este livro é uma referência essencial para quem está projetando ou implementando um data warehouse, oferecendo diretrizes claras para modelagem dimensional.
- Marz, N., & Warren, J. (2015). ***Big Data: Principles and Best Practices of Scalable Realtime Data Systems***. Manning Publications. Aborda conceitos fundamentais e melhores práticas para o design e implementação de sistemas de dados em larga escala, com foco em arquiteturas que permitem análise em tempo real.
- Kleppmann, M. (2017). ***Designing Data-Intensive Applications: The Big Ideas Behind Reliable, Scalable, and Maintainable Systems***. O'Reilly Media. Este livro é recomendado para desenvolvedores e arquitetos de sistemas que desejam construir aplicações que gerenciam, processam e analisam grandes volumes de dados, oferecendo uma visão sobre como projetar sistemas de dados robustos e escaláveis.



Linha de Pesquisa TCC

Implementação de um Pipeline de Dados